



Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ _____ ИНФОРМАТИКА И СИСТЕМЫ УПРАВЛЕНИЯ _____

КАФЕДРА _____ СИСТЕМЫ ОБРАБОТКИ ИНФОРМАЦИИ И УПРАВЛЕНИЯ _____

ОТЧЕТ

ПО РУБЕЖНОМУ КОНТРОЛЮ №1

По дисциплине «Методы машинного обучения»

Студент ИУ5И-21М
(Группа)

(Подпись, дата) Чжоу Чэньюй
(И.О.Фамилия)

Преподаватель

(Подпись, дата) Г.Ю. Евгеньевич
(И.О.Фамилия)

ВВЕДЕНИЕ

В современных задачах машинного обучения качество исходных данных непосредственно определяет эффективность построенных моделей. Реальные наборы данных часто содержат признаки с ненормальным распределением, избыточной размерностью и большим количеством шума, что приводит к снижению точности прогнозирования, увеличению времени обучения и проблеме переобучения. Поэтому этап предобработки данных — нормализация, масштабирование и отбор информативных признаков — является критически важным звеном в пайплайне анализа данных.

Первая задача настоящего отчёта посвящена нормализации числовых признаков методом преобразования Йео–Джонсона (Yeo–Johnson transformation). Многие алгоритмы машинного обучения, такие как линейная регрессия, метод опорных векторов и нейронные сети, чувствительны к асимметрии распределения входных переменных. Преобразование Йео–Джонсона представляет собой обобщение метода Бокса–Кокса, способное работать как с положительными, так и с отрицательными значениями. Оно автоматически подбирает оптимальный параметр λ методом максимального правдоподобия, минимизируя асимметрию распределения и приближая его к нормальному. В работе на примере набора данных California Housing демонстрируется эффективность данного преобразования для признака MedInc (средний доход), характеризующегося выраженной правой асимметрией.

Вторая задача связана с процедурой отбора признаков (feature selection) на основе метода фильтрации — класса SelectPercentile с функцией оценки mutual_info_classif. При высокой размерности пространства признаков модели

становятся сложными, неинтерпретируемыми и склонными к переобучению. Метод взаимной информации позволяет оценить степень зависимости каждого признака от целевой переменной с учётом как линейных, так и нелинейных связей. Параметр `percentile=5` обеспечивает отбор ограниченного числа наиболее информативных признаков, что способствует снижению размерности данных без существенной потери предсказательной способности. Для демонстрации используется классический набор данных `Breast Cancer Wisconsin`, содержащий 30 количественных признаков, описывающих характеристики клеточных ядер опухоли.

Настоящий отчёт состоит из двух разделов, каждый из которых включает описание соответствующего метода обработки данных, программную реализацию на языке Python с использованием библиотек `scikit-learn`, `pandas` и `matplotlib`, анализ полученных результатов и визуализацию. В соответствии с требованиями учебной группы ИУ5И-21М в работе дополнительно приведены диаграммы рассеяния для пар признаков используемых наборов данных.

Часть 1. Описание набора данных

1. Набор данных California Housing

Набор данных California Housing (California Housing Prices Dataset) является классическим регрессионным датасетом, встроенным в библиотеку scikit-learn. Он содержит информацию о средней стоимости жилья в различных районах штата Калифорния, собранную на основе переписи населения 1990 года. Набор данных широко используется в учебных целях для демонстрации методов регрессии и предобработки данных.

Датасет включает 20 640 записей (блоков переписи) и 9 числовых признаков. Целевая переменная — MedHouseVal (средняя стоимость дома в блоке), выраженная в сотнях тысяч долларов. Восемь независимых переменных описывают демографические и географические характеристики районов: MedInc — средний доход домохозяйств, HouseAge — средний возраст жилых зданий, AveRooms и AveBedrms — среднее число комнат и спален на домохозяйство, Population — численность населения блока, AveOccup — среднее число жильцов в домохозяйстве, а также Latitude и Longitude — географические координаты.

Признак MedInc (средний доход), выбранный для демонстрации преобразования Йео–Джонсона, характеризуется выраженной правой асимметрией: минимальное значение составляет 0,50, максимальное — 15,00, медиана — 3,53, а среднее — 3,87. Коэффициент асимметрии (skewness) равен приблизительно 1,65, что свидетельствует о сильном перекосе распределения вправо: большинство значений сосредоточено в нижнем диапазоне, однако присутствует длинный правый хвост с высокими доходами. Такая асимметрия

типична для экономических данных и создаёт предпосылки для применения нормализующих преобразований. После преобразования Йео–Джонсона с оптимальным параметром $\lambda \approx -0,20$ асимметрия снижается практически до нуля, а распределение становится близким к симметричному, что повышает качество работы многих алгоритмов машинного обучения.

Таблица 1 - основные числовые характеристики используемых столбцов.

	MedInc	HouseAge	AveRooms	AveBedrms	Population	AveOccup	Latitude	Longitude	MedHouseVal
count	20640.000000	20640.000000	20640.000000	20640.000000	20640.000000	20640.000000	20640.000000	20640.000000	20640.000000
mean	3.870671	28.639486	5.429000	1.096675	1425.476744	3.070655	35.631861	-119.569704	2.068558
std	1.899822	12.585558	2.474173	0.473911	1132.462122	10.386050	2.135952	2.003532	1.153956
min	0.499900	1.000000	0.846154	0.333333	3.000000	0.692308	32.540000	-124.350000	0.149990
25%	2.563400	18.000000	4.440716	1.006079	787.000000	2.429741	33.930000	-121.800000	1.196000
50%	3.534800	29.000000	5.229129	1.048780	1166.000000	2.818116	34.260000	-118.490000	1.797000
75%	4.743250	37.000000	6.052381	1.099526	1725.000000	3.282261	37.710000	-118.010000	2.647250
max	15.000100	52.000000	141.909091	34.066667	35682.000000	1243.333333	41.950000	-114.310000	5.000010

2. Набор данных Breast Cancer Wisconsin

Набор данных Breast Cancer Wisconsin (Diagnostic) — это широко известный классификационный датасет, доступный в библиотеке scikit-learn. Он основан на результатах анализа цифровых изображений тонкоигольных аспиратов опухолей молочной железы (FNA), выполненных в Висконсинской университетской больнице доктором Уильямом Уолбергом. Каждая запись соответствует одному случаю опухоли и содержит количественные характеристики ядер клеток, извлечённые из оцифрованных изображений.

Датасет включает 569 наблюдений и 30 числовых признаков, вычисленных на основе десяти базовых характеристик ядер. Каждая базовая характеристика представлена тремя статистиками: mean (среднее значение), standard error (стандартная ошибка) и worst (наихудшее/наибольшее значение). Признаки описывают геометрические и текстурные свойства клеточных ядер: радиус, текстуру, периметр, площадь, гладкость, компактность, вогнутость, вогнутые

точки, симметрию и фрактальную размерность. Целевая переменная бинарная: 0 — злокачественная опухоль (malignant, 212 случаев), 1 — доброкачественная (benign, 357 случаев).

Все признаки являются непрерывными числовыми переменными и не содержат пропусков, что исключает необходимость предварительной очистки данных. Диапазоны значений признаков существенно различаются: например, средний радиус (mean radius) колеблется от 6,98 до 28,11, в то время как средняя гладкость (mean smoothness) — от 0,05 до 0,16. Именно эта разнородность масштабов в сочетании с высокой размерностью делает набор данных удобным для демонстрации методов отбора признаков. Метод взаимной информации с параметром percentile=5 отбирает наиболее информативные признаки, в первую очередь из группы «worst», характеризующие наихудшие значения морфологических параметров, что логично с точки зрения медицинской диагностики, поскольку именно экстремальные значения признаков наиболее сильно коррелируют с злокачественностью опухоли.

Таблица 2 - Распределение классов целевой переменной

target	Класс	Количество	Доля
1	benign	357	0.627400
0	malignant	212	0.372600

Часть 2. Преобразование Йео-Джонсона


Для набора данных California Housing проведена нормализация числового признака MedInc (средний доход домохозяйств в блоке) с использованием преобразования Йео-Джонсона. Целью является устранение выраженной правой асимметрии распределения и приближение его к нормальному виду.

Преобразование Йео-Джонсона (Yeo-Johnson transformation) — это обобщение метода Бокса-Кокса, которое поддерживает как положительные, так и отрицательные значения. Преобразование стабилизирует дисперсию и уменьшает асимметрию распределения. Оптимальный параметр λ подбирается методом максимального правдоподобия.

Преимущество данного метода перед Вох-Сох заключается в универсальности: он применим к любым вещественным числам, включая ноль и отрицательные значения. В библиотеке scikit-learn реализация доступна через класс `PowerTransformer(method='yeo-johnson')`

Перед применением преобразования проведён анализ исходного распределения признака MedInc. Вычислен коэффициент асимметрии skewness = 1,6465, что свидетельствует о сильной правой асимметрии. На гистограмме видно, что основная масса значений сосредоточена в диапазоне 0–5, при этом присутствует длинный правый хвост до 15. Q-Q plot относительно нормального распределения демонстрирует существенные отклонения от диагональной линии, особенно в области высоких значений.


Рис.1 Визуализация исходного распределения



С использованием класса `'PowerTransformer(method='yeo-johnson', standardize=False)'` проведено преобразование признака MedInc. Оптимальный параметр λ , подобранный автоматически, составил $-0,1985$. После преобразования коэффициент асимметрии снизился до $-0,0025$, что практически соответствует симметричному распределению.

На гистограмме преобразованного распределения видно, что форма стала близка к колоколообразной, среднее и медиана практически совпали. Q-Q plot демонстрирует значительно лучшее совпадение с нормальным распределением — точки лежат ближе к диагональной прямой.


Рис.2 Визуализация распределения после преобразования



Для наглядного сравнения построены четыре графика: гистограммы и boxplot исходного и преобразованного распределений. Видно, что после преобразования Йео–Джонсона правый хвост исчез, межквартильный размах стал более симметричным, а медиана сместилась к центру.

Сводная таблица статистик подтверждает улучшение: skewness снизился с 1,6465 до $-0,0025$, kurtosis приблизился к нулю. Это свидетельствует о том, что преобразование успешно нормализовало распределение признака MedInc.


Рис.3 Сравнительная визуализация и сводная таблица статистик



В соответствии с требованиями группы ИУ5И-21М построены диаграммы рассеяния для пар признаков набора данных California Housing. На первой диаграмме (MedInc vs AveRooms) наблюдается положительная корреляция:


районы с более высокими доходами характеризуются большим средним числом комнат и более высокой стоимостью жилья (цветовая шкала MedHouseVal).

Рис.4 Диаграмма рассеяния: MedInc vs AveRooms



Вторая диаграмма (HouseAge vs MedInc) не демонстрирует явной линейной зависимости между возрастом домов и уровнем дохода, что указывает на слабую корреляцию данных признаков.

Рис.5 Диаграмма рассеяния: HouseAge vs MedInc



Часть 3. Отбор признаков методом feature selection

Набор данных Breast Cancer Wisconsin содержит 569 наблюдений и 30 числовых признаков, описывающих характеристики ядер клеток опухолей молочной железы. Признаки вычислены на основе десяти базовых свойств (радиус, текстура, периметр, площадь, гладкость, компактность, вогнутость, вогнутые точки, симметрия, фрактальная размерность), каждое из которых представлено статистиками mean, standard error и worst.

Целевая переменная бинарная: 0 — злокачественная опухоль (malignant, 212 случаев), 1 — доброкачественная (benign, 357 случаев). Пропусков в данных нет.

Метод фильтрации SelectPercentile относится к категории одностадийных (filter) методов отбора признаков. Он оценивает каждый признак независимо от остальных на основе заданной статистической функции и отбирает заданный процент признаков с наибольшими значениями.

Взаимная информация (mutual information) измеряет количество информации, которую один случайный процесс содержит о другом. В отличие от корреляции Пирсона, mutual information способна улавливать произвольные (в том числе нелинейные) зависимости между признаком и целевой переменной. Для классификации используется функция ``mutual_info_classif``

Применение SelectPercentile с параметром percentile=5 к набору из 30 признаков привело к отбору двух наиболее информативных переменных: worst perimeter (MI = 0,4757) и worst area (MI = 0,4634). Таким образом, размерность данных сократилась на 93,3% (с 30 до 2 признаков).

Анализ полного рейтинга показывает, что наибольшую предсказательную

ценность имеют признаки группы «worst», характеризующие наихудшие значения морфологических параметров клеточных ядер. Это логично с медицинской точки зрения: злокачественные опухоли ассоциируются с наиболее аномальными значениями размеров и форм ядер.

Рис.6 Горизонтальная столбчатая диаграмма оценок взаимной информации




Рис.7 Топ-10 признаков по взаимной информации





Таблица 3 Рейтинг признаков по взаимной информации

	Признак	Mutual_Info_Score	Отобран
22	worst perimeter	0.473592	True
23	worst area	0.464847	True
20	worst radius	0.454710	False
7	mean concave points	0.441223	False
27	worst concave points	0.436931	False
2	mean perimeter	0.402014	False
6	mean concavity	0.372661	False
0	mean radius	0.365484	False
3	mean area	0.358687	False
13	area error	0.339990	False
26	worst concavity	0.314839	False
12	perimeter error	0.274376	False
10	radius error	0.247168	False
25	worst compactness	0.226316	False
5	mean compactness	0.211431	False
17	concave points error	0.125960	False
21	worst texture	0.119646	False
16	concavity error	0.119075	False

	Признак	Mutual_Info_Score	Отобран
24	worst smoothness	0.106426	False
1	mean texture	0.098301	False
28	worst symmetry	0.095198	False
4	mean smoothness	0.081222	False
15	compactness error	0.077094	False
29	worst fractal dimension	0.066743	False
8	mean symmetry	0.066694	False
19	fractal dimension error	0.039937	False
14	smoothness error	0.016655	False
18	symmetry error	0.013886	False
9	mean fractal dimension	0.007615	False
11	texture error	0.000141	False


Построены диаграммы рассеяния для визуализации разделения классов опухолей в пространстве признаков. На первой диаграмме (отобранные признаки worst perimeter и worst area) наблюдается достаточно чёткое разделение злокачественных и доброкачественных образцов: злокачественные опухоли сосредоточены в области высоких значений обоих признаков.

Рис.8 Диаграмма рассеяния для двух наиболее информативных признаков



Вторая диаграмма (mean radius vs mean texture) демонстрирует классическое разделение классов, где злокачественные опухоли характеризуются большими значениями радиуса ядер.

Рис.9 Дополнительная диаграмма рассеяния: mean radius vs mean texture



ЗАКЛЮЧЕНИЕ

В ходе выполнения рубежного контроля №1 были изучены и применены на практике два метода обработки данных.

В первой задаче продемонстрирована эффективность преобразования Йео–Джонсона для нормализации числового признака MedInc из набора California Housing. Исходное распределение с сильной правой асимметрией ($\text{skewness} = 1,65$) после преобразования стало практически симметричным ($\text{skewness} = -0,0025$), что подтверждено визуальным анализом гистограмм и Q-Q plot. Преимущество данного метода перед Вох-Сох заключается в возможности работы с произвольными вещественными значениями.

Во второй задаче проведён отбор признаков из набора Breast Cancer Wisconsin методом SelectPercentile с взаимной информацией. При параметре percentile=5 из 30 признаков отобраны 2 наиболее информативных (worst perimeter и worst area), что позволило сократить размерность данных на 93,3% при сохранении наиболее значимой предсказательной информации.

Оба метода являются важными инструментами предобработки данных в задачах машинного обучения и способствуют повышению качества и интерпретируемости моделей.